

گزارش تحلیل داده

پروژه طبقه‌بندی انواع لوبیا

مقایسه کلاس‌های واقعی با خوشه‌های K-Means

دیتاست: Dry Bean Dataset

منبع: UCI Machine Learning Repository

نقش: تحلیلگر داده

پروژه دانشگاهی - تحلیل داده

دیتاست Dry Bean شامل اطلاعات ۱۳,۶۱۱ دانه لوبیا از هفت نوع مختلف است. ویژگی‌های هر دانه از تصاویر با دوربین با وضوح بالا استخراج شده‌اند.

تعداد نمونه‌ها: ۱۳,۶۱۱

تعداد ویژگی‌ها: ۱۶ ویژگی عددی

ستون هدف: Class با هفت نوع لوبیا

BARBUNYA - BOMBAY - CALI - DERMASON - HOROZ - SEKER - SIRA

یکسان‌سازی نام ستون‌ها

دو نام ستون در فایل خام تصحیح شدند:

AspectRatio → AspectRatio و roundness → Roundness

این اصلاح صرفاً برای یکسان‌سازی نام ستون‌ها در Notebook انجام شده و فایل خام دیتاست دست‌کاری نشده است.

مقادیر گم‌شده

هیچ مقدار گم‌شده‌ای در هیچ‌یک از ۱۷ ستون وجود ندارد. نیازی به Imputation نیست.

ردیف‌های تکراری

تعداد ۶۸ ردیف تکراری شناسایی شد (۰.۵ درصد). تصمیم: ردیف‌های تکراری حذف نشدند.

مقادیر غیر عددی

تمام ۱۶ ستون ویژگی کاملاً عددی هستند.

مقادیر پرت آماری — IQR Outlier

مقادیر پرت بر اساس روش IQR شناسایی شدند. تصمیم: هیچ مقدار پرتی حذف نشد. مقادیر پرت ممکن است تفاوت‌های طبیعی بین کلاس‌ها باشند.

بررسی محدوده منطقی — Range Validation

مستقل از IQR، محدوده منطقی هر ویژگی بررسی شد. قوانین اعتبارسنجی:

ویژگی‌های هندسی (Area, Perimeter, ...): مقدار < 0

محدوده $[0, 1]$ — صفر معتبر، یک نامعتبر: Eccentricity

محدوده $[0, 1]$: Extent, Solidity, Roundness, Compactness

Invalid Range Values = 0

تمام مقادیر در محدوده منطقی مورد انتظار قرار دارند.

نکته مهم:

یکی نیست Invalid Range با IQR Outlier

یک مقدار می‌تواند از نظر آماری Outlier باشد

اما همچنان در محدوده منطقی ویژگی قرار داشته باشد.

شناسایی Outlier به معنی خطا بودن داده نیست.

بخش ۳ – توزیع کلاس‌ها

نمونه (۲۶.۰۵ درصد) — بزرگ‌ترین کلاس DERMASON: ۳,۵۴۶

(نمونه ۱۹.۳۷ درصد SIRA: ۲,۶۳۶)

(نمونه ۱۴.۸۹ درصد SEKER: ۲,۰۲۷)


(نمونه ۱۴.۱۷ درصد HOROZ: ۱,۹۲۸)

(نمونه ۱۱.۹۸ درصد CALI: ۱,۶۳۰)

(نمونه ۹.۷۱ درصد BARBUNYA: ۱,۳۲۲)

نمونه (۳.۸۴ درصد) — کوچک‌ترین کلاس BOMBAY: ۵۲۲

نسبت بزرگ‌ترین به کوچک‌ترین: ۶.۷۹ برابر



تحلیل: دیتاست نامتوازن است.

مستقیماً از برجسب واقعی کلاس‌ها استفاده نمی‌کند K-Means

و اندازه خوشه‌های حاصل الزاماً با تعداد نمونه‌های کلاس‌های واقعی برابر نیست.

مناسب‌تر هستند Macro Recall و Macro F1

میانگین ۵۳,۰۴۸ | میانه ۴۴,۶۵۲ | انحراف معیار ۲۹,۳۲۴ Area:

میانگین ۸۵۵ | میانه ۷۹۵ | انحراف معیار ۲۱۴ Perimeter:

میانگین ۰.۷۵ | میانه ۰.۷۶ Eccentricity:

میانگین ۰.۸۷ | میانه ۰.۸۸ Roundness:


میانگین ۰.۸۰ | میانه ۰.۸۰ Compactness:

نکات مهم:

۱. تفاوت مقیاس بسیار زیاد بین ویژگی‌ها

کوچک‌ترین دانه‌ها SEKER/DERMASON بزرگ‌ترین و BOMBAY ۲.

نمودار ۱: هیستوگرام ویژگی Area




توزیع چوله به راست است.

اکثر نمونه‌ها بین ۲۰,۰۰۰ تا ۸۰,۰۰۰ تمرکز دارند.

بدون Scale، این ویژگی بر فاصله تسلط می‌یابد.


نمودار ۲: Boxplot ویژگی Area به تفکیک Class



به وضوح از سایرین جدا است BOMBAY


همپوشانی زیادی دارند DERMASON و SEKER

نمودار ۳: Area در مقابل Perimeter



رابطه مثبت و بسیار قوی بین Area و Perimeter.
همبستگی بالا نشان‌دهنده اطلاعات مشابه است.


نمودار ۴: Compactness در مقابل Eccentricity



رابطه منفی قوی بین این دو ویژگی شکلی.

کشیده: HOROZ. فشرده و گرد: BOMBAY.

نمودار ۵: ماتریس همبستگی



همبستگی بالای ۰.۹۵: Area، Perimeter، ConvexArea و EquivDiameter

۱۶ ویژگی اطلاعات مستقل ندارند.

مشکل واحدها را حل می‌کند ولی مشکل ویژگی‌های تکراری را کاملاً حل Scale نمی‌کند.

طبق دستورالعمل پروژه، PCA لازم نیست.