

گزارش نهایی پروژه: تشخیص انواع لوبیا با KNN و مقایسه کلاس‌های واقعی با خوشه‌های K-Means

دیتاست Dry Bean (UCI) با 13,611 دانه، 16 ویژگی هندسی و 7 کلاس. همه اعداد از اجرای نوت‌بوک به دست آمده‌اند و با random_state=42 تکرارپذیرند.

1. مقدمه، هدف و توصیف داده

دو پرسش بررسی شد: (1) آیا KNN می‌تواند نوع لوبیا را از روی ویژگی‌های هندسی تشخیص دهد؟ (2) آیا هفت خوشه K-Means که بدون دیدن برچسب ساخته می‌شوند، با هفت کلاس واقعی مطابقت دارند؟ داده شامل 13,611 نمونه (هر ردیف یک دانه)، 16 ویژگی عددی (Area, Perimeter, MajorAxisLength, MinorAxisLength, AspectRatio, Eccentricity, ConvexArea, EquivDiameter, Extent, Solidity, Roundness, Compactness, Barbunya, Bombay, Cali, Dermason, Class) و ستون هدف Class با هفت کلاس است: Sira, Horoz, Seker, Sira و Horoz. ستون Class فقط هدف است و در هیچ مدلی جزو ورودی نبود (در نوت‌بوک با assert و میزبانی نشد بررسی می‌شود). نام دو ستون فایل خام (roundness و AspectRatio) فقط برای یکدستی به AspectRatio و Roundness تغییر یافت.

2. کیفیت داده

- مقدار گم‌شده: صفر. مقدار غیر عددی یا بی‌نهایت در ویژگی‌ها: صفر. مقدار خارج از محدوده منطقی: 0 مورد؛ قاعده‌ها برای 12 ویژگی بررسی شدند (اندازه‌ها $0 < Eccentricity$, $AspectRatio \geq 1$ در $[0,1]$ و $Extent/Solidity/Roundness/Compactness$ در $[0,1]$).
- ردیف تکراری: 68 ردیف تکراری (0.50%) در 68 جفت؛ همه آنها متعلق به کلاس Horoz اند و هیچ ویژگی یکسانی برچسب متفاوت ندارد. تصمیم: حذف نشدند. دلیل: (الف) پروژه حذف خودکار را نمی‌خواهد و دو دانه متفاوت می‌توانند اندازه‌گیری هندسی یکسان داشته باشند؛ (ب) تکرار فقط در یک کلاس رخ داده و ممکن است سیگنال واقعی باشد نه خطای ثبت؛ (ج) خطر اصلی، نشست بین Train و Test است، پس اثرش اندازه‌گیری شد نه حدس زده: فقط 23 ردیف (0.84%) Test یک همزاد دقیق در Train دارند و Accuracy برای $K=5$ با و بدون آنها 0.9166 و 0.9167 است. اگر مدل نهایی در محیط واقعی ساخته شود، حذف تکراری‌ها پیش از تقسیم‌گزینه محافظه‌کارانه‌تر است، ولی برای این تکلیف تغییر نتیجه‌ای ندارد.
- مقادیر پرت (IQR): بیشترین سهم در Eccentricity (6.19%)، Solidity (5.72%) و ShapeFactor4 (5.64%). Area (5.64%) حدود 4.05% (عمدتاً دانه‌های درشت Bombay). این‌ها خطا نیستند و حذف نشدند، ولی K- و KNN به آن‌ها حساس‌اند.



3. توزیع کلاس‌ها و عدم توازن

کلاس‌ها متوازن نیستند: Dermason (3,546 نمونه، 26.05%) و کوچک‌ترین Bombay (522 نمونه، 3.84%) است؛ نسبت 6.793 به 1. مدلی که همه چیز را Dermason بگوید بدون یادگیری حدود 26% Accuracy دارد. چون Accuracy کلاس‌های بزرگ را بیشتر وزن می‌دهد، خطای کامل روی یک کلاس کوچک در آن تقریباً دیده نمی‌شود؛ پس Recall و F1 هر کلاس و میانگین Macro هم گزارش شد.

4. تحلیل اکتشافی و آماری

میانگین Area کلاس‌ها از حدود 32 هزار (Dermason) تا 173 هزار (Bombay) تغییر می‌کند (نسبت 5.4)، اما میانگین Roundness و Compactness فقط 1.19 و 1.28 برابر تفاوت دارد؛ یعنی اندازه Bombay را جدا می‌کند و بقیه کلاس‌ها را بیشتر شکل از هم متمایز می‌کند. توزیع Area چوله به راست است (چولگی 2.95؛ میانگین 53,048 بیشتر از میانه 44,652). Bombay در Boxplot کاملاً جداسافت و Sira, Seker و Dermason هم‌پوشانی دارند. جدول 1 آمار توصیفی هفت ویژگی اصلی است (P25/P50/P75 و میانگین هر کلاس در tables/ ذخیره شده‌اند).

Feature	Mean	Median	Std	Min	Max	P90
Area	53,048	44,652	29,324	20,420	254,616	78,114
Perimeter	855	795	214	525	1,985	1,094
MajorAxisLength	320	297	86	184	739	417
MinorAxisLength	202	192	45	123	460	247
Eccentricity	0.751	0.764	0.092	0.219	0.911	0.861
Roundness	0.873	0.883	0.060	0.490	0.991	0.945
Compactness	0.800	0.801	0.062	0.641	0.987	0.888



شکل 1 (راست): تعداد و درصد هر کلاس؛ شکل 2 (چپ): Boxplot ویژگی Area به تفکیک کلاس

5. تقسیم داده، Scale و اعتبار روش (بدون نشت)

تقسیم با `train_test_split` و `random_state=42` و `test_size=0.2` و `stratify=y` انجام شد: `Train = 10,888` و `Test = 2,723` نمونه؛ درصد هر کلاس در `Train` و `Test` با درصد کل حداکثر 0.05 واحد تفاوت دارد. `StandardScaler` فقط روی `Train` آموزش دید (fit) و روی `Train` و `Test` فقط `transform` شد؛ میانگین و انحراف معیار `Train` پس از `Scale` دقیقاً 0 و 1 است و برای `Test` نزدیک آنها (مثلاً میانگین `Area` در `Test` برابر 0.005). در `Cross-Validation` هم `Scaler` درون `Pipeline` و در هر `Fold` دوباره آموزش می‌بیند. نوبت بک 12 آزمون صریح نشت (شامل بازتولید تقسیم، تفاوت میانگین `Scaler` با میانگین کل داده، و fit فقط روی `Train` برای `KNN` و `K-Means`) را اجرا می‌کند و همه قبول شدند.

چرا Scale؟ `KNN` و `K-Means` بر فاصله اقلیدسی تکیه دارند. در داده‌های خام، `Area` و `ConvexArea` به‌تنهایی حدود 100% (49% + 51%) مربع فاصله اقلیدسی بین دو دانه را می‌سازند و `Roundness` یا `Solidity` عملاً نادیده گرفته می‌شوند. اثر عملی: `Test Accuracy` در `KNN (K=5)` از 0.724 (بدون `Scale`) به 0.917 (با `Scale`) و `ARI` در `K-Means` از 0.38 به 0.67 می‌رسد. `Scale` مشکل واحدها و دامنه‌ها را حل می‌کند، نه هم‌بستگی و افزونگی ویژگی‌ها را (بخش 10).

6. روش و نتایج KNN


`KNeighborsClassifier` با فاصله اقلیدسی پیش‌فرض و `K = 3, 5` و 9 روی ویژگی‌های `Scale` شده `Train` آموزش دید و روی `Test` سنجیده شد. ردیف آخر جدول 2 فقط مرجع (بدون `Scale`) است.

Model	K	Scaling	Train Acc	Test Acc	Macro Recall	Macro F1
KNN	3	Yes	0.9499	0.9152	0.9274	0.9285
KNN	5	Yes	0.9415	0.9166	0.9271	0.9293
KNN	9	Yes	0.9368	0.9163	0.9267	0.9289
KNN	5	No (reference)	0.8127	0.7242	0.7229	0.7270

جدول 2: نتایج `K=3, 5` و `KNN` روی 9 `Test` تقریباً یکسان‌اند: اختلاف `Accuracy` حدود 0.0015 (حدود 4 نمونه از 2,723) است، در حالی که خطای معیار `Accuracy` حدود 0.0053 (بازه 95% حدود ± 0.010) است. پس از این تفاوت‌ها نمی‌توان «بهترین `K` عمومی» نتیجه گرفت. `Train Accuracy` با بزرگ‌تر شدن `K` کاهش می‌یابد (از 0.950 به 0.937) چون مدل هموارتر می‌شود؛ این روی تعمیم‌پذیری `Test` اثری نشان نداد. برای انتخاب حرفه‌ای `5-Fold Cross-Validation`، `K` فقط روی `Train` (با `Scaler` درون `Fold`) اجرا شد: `K=1` به‌وضوح ضعیف‌تر است (Macro-F1 برابر 0.9205)، از `K=5` تا 21 منحنی تقریباً تخت است (بیشینه در `K=9` با 0.9373 و `K=11` با 0.9372) و اختلاف‌ها هم‌مرتبه انحراف معیار `Fold`‌ها (0.004 تا 0.006) است.

Class (K=5, Test)	Precision	Recall	F1	Support
Barbunya	0.951	0.875	0.912	265
Bombay	1.000	1.000	1.000	104
Cali	0.917	0.945	0.931	326
Dermason	0.910	0.911	0.911	709
Horoz	0.953	0.946	0.949	386
Seker	0.950	0.943	0.947	406
Sira	0.843	0.869	0.856	527

7. ماتریس اغتشاش هفت کلاسه



شکل 3: ماتریس اغتشاش KNN با K=5 روی Test (اعداد و درصد سطری؛ ماتریس‌های K=3 و K=9 در figures و tables ذخیره شده‌اند)

- **بیشترین پیش‌بینی صحیح:** Dermason با 646 نمونه؛ عمدتاً چون بزرگ‌ترین کلاس است. **کمترین Recall:** Sira با 0.869، و بلافاصله Barbunya با 0.875 (در K=9 ترتیب این دو عوض می‌شود، پس در حد نوسان برابرند). Bombay با Precision و Recall برابر 1.0 کاملاً جداست.
- **بیشترین اشتباه:** Sira ↔ Dermason: 53 خطا از Dermason به Sira و 51 خطا از Sira به Dermason، جمعاً 104 خطا. جفت بعدی Cali ↔ Barbunya با 29 خطاست.
- **دلیل بر اساس ویژگی‌ها:** شکل Sira و Dermason شبیه است: تفاوت میانگین Extent و Solidity (0.09) کمتر از 0.1 انحراف معیار (Cohen d) و برای Eccentricity, Compactness, Roundness (0.09) تفاوت اصلی اندازه است (Area حدود 32 هزار در برابر 45 هزار؛ d = 2.7)، ولی دامنه Sira وسیع است و در ناحیه مرزی با Dermason هم‌پوشانی می‌کند. Cali و Barbunya هر دو دانه‌های درشت‌اند (Area حدود 70 و 76 هزار).

8. روش و نتایج K-Means


KMeans با n_clusters=7، random_state=42 و n_init=10 فقط روی 16 ویژگی عددی Scale شده Train آموزش دید؛ ستون Class هرگز استفاده نشد. سپس Cluster نمونه‌های Test با predict تعیین شد. شماره Cluster فقط یک شناسه است، پس هیچ **Accuracy مستقیمی بین شماره Cluster و Class محاسبه نشد؛** به جای آن از Crosstab، Purity و (نگاشت مستند اکثریت) استفاده شد. جدول 3 Crosstab روی Test است.

Class \ Cluster	0	1	2	3	4	5	6
Barbunya	4	233	0	0	21	1	6
Bombay	0	0	0	103	0	0	1
Cali	2	266	0	0	3	6	49
Dermason	21	0	581	0	105	0	2
Horoz	0	6	0	0	13	332	35
Seker	378	0	9	0	19	0	0
Sira	6	0	34	0	470	10	7


Cluster	Dominant class	Train	Train purity	Test	Test purity	Other classes (Train, ≥5%)
0	Seker	1,618	92.3%	411	92.0%	Dermason (5.7%)
1	Cali	2,001	53.1%	505	52.7%	Barbunya (45.4%)
2	Dermason	2,557	91.8%	624	93.1%	Sira (6.4%)
3	Bombay	417	100.0%	103	100.0%	-
4	Sira	2,468	75.0%	631	74.5%	Dermason (15.4%)
5	Horoz	1,423	93.7%	349	95.1%	-
6	Cali	404	48.5%	100	49.0%	Horoz (36.1%), Barbunya (7.7%)

جدول 4: خلوص هر **Purity** Cluster. **کلی:** 79.9% روی Train و 80.0% روی Test (نگاشت اکثریت گرفته شده از Train روی Test نیز 80.0% می‌دهد). این عدد با ARI=0.674، NMI=0.722 (Train) و Silhouette=0.31 خوانده شود. Purity با افزایش

تعداد خوشه‌ها بالا می‌رود و نگاشت اکثریت چندبیه است: **Barbunya** در هیچ **Cluster** غالب نیست و با این نگاشت هرگز پیش‌بینی نمی‌شود.



شکل 4: Eccentricity در برابر Area با محورهای یکسان؛ چپ: کلاس واقعی، راست: Cluster (Test). نمودار جفت Compactness/Roundness در figures/ است.



شکل 5 (راست): هیتمپ Crosstab کلاس-Cluster روی Test (رنگ = درصد کلاس در Cluster، عدد = تعداد)؛ شکل 6 (چپ): انتخاب K با Train روی Cross-Validation

- **انطباق تقریبی** (درصدها از Train): Cluster 3 دقیقاً Cluster 0 (100%)، Cluster 2 عمدتاً Dermason (92%) و Cluster 5 عمدتاً Horoz (94%).
- **یک کلاس در چند Cluster**: حدود 13% Dermason در Train (15% در Test) در Cluster 4؛ حدود 15% Cali و 9 تا 10% Horoz در Cluster 6؛ Barbunya بین Clusterهای 1، 4 و 6 پخش است.
- **یک Cluster با چند کلاس**: Cluster 1 نیمه Cali (53%) و نیمه Barbunya (45%)؛ Cluster 6 ترکیب Cali (49%) و Horoz (36%)؛ Cluster 4 (Sira با 75%) حدود 15% Dermason دارد.
- **چرا 7 خوشه ≠ کشف دقیق 7 کلاس؟** $n_clusters=7$ فقط تعداد ناحیه‌ها را تعیین می‌کند؛ K-Means گروه‌های گرد و فشرده می‌سازد، در حالی که کلاس‌ها هم‌پوشان (Barbunya/Cali، Sira/Dermason)، کشیده (Horoz) یا چندزیرگروه‌اند. بیشترین Silhouette در $k=3$ (0.41) است و $k=7$ مقدار 0.31 دارد؛ خود داده هفت گروه کاملاً جدا پیشنهاد نمی‌کند. با $random_state=7$ گروه‌بندی تقریباً یکسان (ARI برابر 0.999) ولی شماره‌ها متفاوت است؛ پس شناسه Cluster معنای کلاس ندارد.

9. مقایسه K-Means و KNN


KNN مدل **نظارت‌شده** است، برچسب را می‌بیند و خروجی‌اش هم‌جنس برچسب است؛ پس Accuracy، Precision و Recall دارد. K-Means **بدون نظارت** است و فقط شناسه گروه می‌دهد که معنی ذاتی ندارد. مقایسه با یک عدد Accuracy نادرست است؛ هر مدل با معیار مناسب خودش (KNN: Macro Recall/F1 و ماتریس اغتشاش؛ K-Means: Crosstab، ARI، NMI، Purity) سنجیده شد. جمع‌بندی: با برچسب، KNN حدود 92% نمونه‌های Test را درست تشخیص می‌دهد (Macro F1 حدود 0.93)؛ بدون برچسب، K-Means تا حدی (ARI برابر 0.67) ساختار کلاس‌ها را بازبایی می‌کند.

10. چالش ابعاد، فاصله و افزونگی ویژگی‌ها

• **ضعف مفهوم فاصله:** با افزایش بُعد، فاصله نزدیک‌ترین و دورترین نقطه به هم نزدیک می‌شود. در شبیه‌سازی ما تفاوت نسبی فاصله دورترین و نزدیک‌ترین نقطه (نسبت به فاصله نزدیک‌ترین) از 122.6 در 2 بُعد به 1.6 در 16 بُعد و 0.13 در 1024 بُعد می‌رسد. 16 بُعد هنوز قابل قبول است، ولی اثر شروع شده و «نزدیک‌ترین همسایه» اطلاعات کمتری دارد.

• **استقلال ویژگی‌ها:** 16 ویژگی مستقل نیستند؛ فقط 4 جهت از 16 جهت 90% واریانس استاندارد شده و 7 جهت 99% آن را می‌سازد و 15 جهت ویژگی $|r| \geq 0.95$ دارند.

• **Area، Perimeter و EquivDiameter:** Area-Perimeter $r=0.967$ ، Area-EquivDiameter $r=0.985$ ، Perimeter-EquivDiameter $r=0.991$ (Area با ConvexArea نیز $r=0.9999$). یک اطلاعات (اندازه) چند بار در فاصله شمرده می‌شود، پس وزن ضمنی اندازه از شکل بیشتر می‌شود. Compactness و Eccentricity هم $r=0.97$ دارند.



شکل 7: ماتریس هم‌بستگی 16 ویژگی؛ بلوک بزرگ (Area، Perimeter، ConvexArea، EquivDiameter، MajorAxisLength، MinorAxisLength) و بلوک شکل (Compactness، Eccentricity، AspectRatio، ShapeFactor3) پرهم‌بستگی‌اند

• **Scale و ویژگی‌های تکراری:** Scale فقط دامنه‌ها را یکسان می‌کند و هم‌بستگی را تغییر نمی‌دهد؛ پس مشکل واحدها حل می‌شود ولی تکراری بودن اطلاعات می‌ماند. (طبق دستور پروژه PCA یا انتخاب ویژگی به کار نرفت و فقط تحلیل شد.)

11. پاسخ پرسش‌های نهایی

1. متوازن؟ خیر؛ نسبت 6.793 به 1 (Bombay در برابر Dermason).
2. کمترین Recall؟ Sira (0.869) و پس از آن Barbunya (0.875).
3. بیشترین اشتباه؟ Dermason و Sira (104 خطا).
4. اثر K؟ برای $K=3/5/9$ بسیار کم (چند نمونه، کمتر از خطای معیار)؛ Train Accuracy با K کاهش می‌یابد؛ CV فقط نشان می‌دهد $K=1$ بدتر است و بازهٔ میانی هم‌ارز.
5. اهمیت Scale؟ بدون Scale، Area و ConvexArea فاصله را تسخیر می‌کنند؛ KNN از 0.724 به 0.917 و K-Means ARI از 0.38 به 0.67 می‌رسد.
6. انطباق Clusterها با کلاس‌ها؟ جزئی (ARI 0.67، NMI 0.72، Purity 80%): Bombay کامل؛ Seker، Dermason و Horoz حدود 92 تا 94%؛ Barbunya و Cali در هم آمیخته‌اند.
7. شمارهٔ Cluster؟ شناسهٔ دلخواه است و با random_state یا اجرای دیگر عوض می‌شود؛ بدون نگاشت مستند معنای کلاس ندارد.
8. تفاوت طبقه‌بندی و خوشه‌بندی؟ در طبقه‌بندی نظارت‌شده مدل از جفت (ویژگی، برچسب) یاد می‌گیرد و برچسب پیش‌بینی می‌کند؛ در خوشه‌بندی بدون نظارت فقط ویژگی‌ها هست و الگوریتم گروه‌های مشابه می‌سازد.
9. محدودیت در خط بسته‌بندی؟ تغییر نور/دوربین/سرعت نوار (Data Drift)؛ دانه‌های چسبیده، شکسته یا ناخالصی و نوع ناشناخته (KNN همیشه یکی از 7 کلاس را می‌دهد)؛ حدود 8% خطا و Precision حدود 0.84 برای Sira؛ وابستگی Precision به ترکیب کلاس‌ها در خط؛ هزینهٔ محاسبهٔ فاصله با کل داده؛ نیاز به آزمون روی داده‌های واقعی در زمان‌های مختلف.

12. نتیجه‌گیری و محدودیت‌ها

نتیجه: ویژگی‌های هندسی به‌تنهایی برای تشخیص نوع لوبیا کافی‌اند: KNN با Scale روی Test حدود 91.7% Accuracy و F1 Macro حدود 0.929 می‌دهد و Bombay را بی‌خطا جدا می‌کند؛ ضعیف‌ترین بخش، جفت Dermason-Sira (و سپس Barbunya-Cali) است. K-Means بدون پرچسب فقط ساختار جزئی را کشف می‌کند (ARI 0.67، Purity 80%) و بدون Scale عملاً بی‌معناست.

محدودیت‌ها: (1) همه نتایج روی یک تقسیم Train/Test هستند و فاصله اطمینان حدود $\pm 1\%$ دارند؛ تفاوت‌های کوچک بین K یا بین مدل‌ها معنادار نیست. (2) 68 ردیف تکراری و مقادیر پرت عمداً حفظ شدند؛ اثر نشت ناشی از تکراری‌ها اندازه‌گیری و ناچیز بود، ولی حذف آن‌ها گزینه دیگری است. (3) تحلیل اکتشافی (هم‌بستگی، میانگین کلاس‌ها) روی کل داده انجام شد و فقط توصیفی است، در آموزش هیچ مدلی نقش نداشت. (4) ویژگی‌ها از تصاویر یک سامانه تصویربرداری استخراج شده‌اند؛ تعمیم به نور، دوربین یا نمونه دیگر آزمون نشده است. (5) K-Means خوشه‌های گرد فرض می‌کند و Purity به تعداد خوشه‌ها و نگاشت اکثریت وابسته است. (6) PCA، انتخاب ویژگی و تنظیم فرایارامتر (وزن فاصله، معیار فاصله) طبق دستور پروژه انجام نشد و می‌تواند در کارهای بعدی بررسی شود.

13. فایل‌های تحویلی و تکرارپذیری

notebooks/Dry_Bean_KNN_KMeans.ipynb (اجرای کامل بدون خطا)، figures، README.md، (13 نمودار از جمله ماتریس اغتشاش هفت‌کلاسه و دو نمودار مقایسه Class/Cluster)، tables (جدول‌ها از جمله Purity، Crosstab و نتایج نهایی KNN و K-Means به‌همراه results_summary.json) و این گزارش. اجرای مجدد: Restart & Run All بدون تغییر در تنظیمات.