

پروژه طبقه‌بندی انواع لوبیا و مقایسه کلاس‌های واقعی با خوشه‌های K-Means

سناریوی پروژه

یک مجموعه فعال در حوزه کشاورزی و بسته‌بندی حبوبات قصد دارد براساس شکل ظاهری دانه‌ها، نوع لوبیا را به‌صورت خودکار تشخیص دهد. ویژگی‌های هر دانه قبلاً از تصویر استخراج شده‌اند و شامل ابعاد، مساحت، محیط و شاخص‌های هندسی هستند.

هدف پروژه ساخت مدل KNN برای طبقه‌بندی هفت نوع لوبیا و سپس بررسی این موضوع است که آیا K-Means می‌تواند بدون مشاهده نام کلاس‌ها، ساختاری مشابه کلاس‌های واقعی پیدا کند یا خیر.

مدت انجام پروژه یک هفته است و پروژه باید توسط یک تیم سه‌نفره انجام شود.

معرفی دیتاست

دیتاست Dry Bean شامل اطلاعات ۱۳۶۱۱ دانه لوبیا از هفت نوع مختلف است. برای هر دانه ۱۶ ویژگی عددی استخراج شده و مقدار گمشده ثبت‌شده‌ای وجود ندارد.

کلاس‌ها:

• Seker

• Barbunya

• Bombay

• Cali

• Dermosan

• Horoz

• Sira

برخی ویژگی‌ها:

• Area

• Perimeter

• MajorAxisLength

• MinorAxisLength

• AspectRatio

• Eccentricity

• ConvexArea

- EquivDiameter
- Extent
- Solidity
- Roundness
- Compactness
- ShapeFactor1 تا ShapeFactor4
- Class: متغیر هدف

صفحه رسمی دیتاست [Dry Bean در UCI](https://archive.ics.uci.edu/static/public/602/dry2%2Bbean2%2Bdataset.zip):

دانلود مستقیم:

<https://archive.ics.uci.edu/static/public/602/dry2%2Bbean2%2Bdataset.zip>

فایل پیشنهادی داخل مجموعه:

DryBeanDataset/Dry_Bean_Dataset.xlsx

برای دریافت داده با Python می‌توان از `ucimlrepo` و شناسه ۶۰۲ استفاده کرد.

هدف اصلی پروژه

پاسخ‌دادن به دو سؤال:

آیا الگوریتم KNN می‌تواند نوع لوبیا را براساس ویژگی‌های هندسی تشخیص دهد؟

آیا هفت خوشه تولیدشده توسط K-Means با هفت کلاس واقعی دیتاست مطابقت دارند؟

الگوریتم‌های الزامی:

- KNN برای Classification
 - K-Means برای Clustering
 - Confusion Matrix برای ارزیابی KNN
- K-Means مدل طبقه‌بندی نیست و نباید مانند KNN ارزیابی شود.

مراحل الزامی پروژه

۱. بارگذاری و شناخت داده

- فایل Excel را با Pandas بارگذاری کنید.
- پنج سطر اول و آخر را نمایش دهید.

- تعداد رکوردها و ستون‌ها را گزارش کنید.
- نوع داده تمام ستون‌ها را بررسی کنید.
- Target و ویژگی‌ها را مشخص کنید.
- هفت مقدار یکتای ستون Class را نمایش دهید.
- برای ویژگی‌ها یک Data Dictionary خلاصه تهیه کنید.

۲. کنترل کیفیت داده

موارد زیر را بررسی کنید:

- مقادیر گم‌شده
- ردیف‌های تکراری
- مقادیر غیر عددی
- مقادیر خارج از محدوده
- تعداد نمونه‌های هر کلاس

داده تکراری بدون بررسی حذف نشود. ممکن است دو دانه متفاوت دارای ویژگی‌های یکسان یا بسیار نزدیک باشند.

۳. بررسی عدم توازن کلاس‌ها

- تعداد و درصد نمونه‌های هر کلاس را محاسبه کنید.
- نمودار Bar کلاس‌ها را رسم کنید.
- بزرگترین و کوچکترین کلاس را مشخص کنید.
- نسبت تعداد بزرگترین کلاس به کوچکترین کلاس را محاسبه کنید.
- توضیح دهید چرا Accuracy کلی ممکن است عملکرد ضعیف روی کلاس کوچک را پنهان کند.

۴. آمار توصیفی

برای ویژگی‌های زیر آمار توصیفی محاسبه کنید:

- Area
- Perimeter
- MajorAxisLength
- MinorAxisLength
- Eccentricity

- Roundness

- Compactness

موارد موردنیاز:

- Mean

- Median

- Standard Deviation

- Maximum و Minimum

- صدک‌های ۲۵، ۵۰، ۷۵ و ۹۰

برای حداقل سه ویژگی، Mean هر کلاس را جداگانه محاسبه و مقایسه کنید.

۵. تحلیل تصویری

حداقل نمودارهای زیر را رسم کنید:

- Histogram و ویژگی Area

- Boxplot و ویژگی Area به تفکیک Class

- Scatter Plot مربوط به Area و Perimeter

- Scatter Plot مربوط به Eccentricity و Compactness

- ماتریس همبستگی ویژگی‌ها

در Scatter Plot ها از رنگ متفاوت برای هر کلاس استفاده کنید.

به دلیل تعداد زیاد داده‌ها، برای رسم Scatter Plot می‌توانید ۲۰۰۰ نمونه را با `random_state=42` انتخاب کنید؛ اما مدل‌ها باید با کل داده Train آموزش داده شوند.

۶. تقسیم Train/Test

- ستون Class را به عنوان y جدا کنید.

- تمام ویژگی‌های عددی را در X قرار دهید.

- داده را به ۸۰ درصد Train و ۲۰ درصد Test تقسیم کنید.

- از `random_state=42` استفاده کنید.

- از `stratify=y` برای حفظ نسبت کلاس‌ها استفاده کنید.

- تعداد اعضای هر کلاس در Train و Test را گزارش کنید.

ستون Class تحت هیچ شرایطی نباید در میان ویژگی‌های مدل قرار گیرد.

۷. Scale

ویژگی‌ها دارای مقیاس‌های بسیار متفاوت هستند؛ برای مثال Area می‌تواند مقادیر بسیار بزرگتری از Roundness داشته باشد.

بنابراین:

- StandardScaler را فقط روی X_{train} آموزش دهید.
- X_{train} و X_{test} را تبدیل کنید.
- اثر Scale بر Mean و Standard Deviation ویژگی‌ها را نمایش دهید.
- توضیح دهید چرا KNN و K-Means به Scale حساس هستند.

۸. مدل KNN

یک مدل KNN با $K=5$ ایجاد کنید.

موارد زیر را گزارش کنید:

- Train Accuracy
- Test Accuracy
- Confusion Matrix هفت‌کلاسه
- Precision، Recall و F1-score هر کلاس
- میانگین Macro برای Recall و F1-score

سپس KNN را با $K=3$ و $K=9$ نیز اجرا کنید و نتایج Test را مقایسه کنید.

این بخش برای مشاهده رفتار مدل است؛ نباید پس از مشاهده مکرر Test ادعا شود که بهترین مقدار عمومی K پیدا شده است. برای انتخاب حرفه‌ای پارامتر باید Validation یا Cross Validation استفاده شود.

۹. تحلیل Confusion Matrix چندکلاسه

Confusion Matrix باید با نام کامل هفت نوع لوبیا رسم شود.

موارد زیر را استخراج کنید:

- کلاسی که بیشترین پیش‌بینی صحیح را دارد
- کلاسی که کمترین Recall را دارد
- دو کلاسی که بیشتر با یکدیگر اشتباه شده‌اند
- تعداد خطای رفت و برگشت میان آن دو کلاس

بررسی کنید ویژگی‌های ظاهری دو کلاس پراشتباه چه شباهتی دارند.

۱۰. اجرای K-Means

الگوریتم K-Means را با تنظیمات زیر اجرا کنید:

`n_clusters = 7`

`random_state = 42`

`n_init = 10`

الزامات:

- K-Means فقط با ویژگی‌های Scale شده Train آموزش ببیند.
 - ستون Class در اختیار K-Means قرار نگیرد.
 - برای نمونه‌های Test شماره Cluster پیش‌بینی شود.
 - تعداد اعضای هر Cluster گزارش شود.
 - جدولی با `pd.crosstab` میان Class واقعی و Cluster تولید شود.
- شماره Cluster ها صرفاً شناسه هستند. برای مثال Cluster 0 الزاماً معادل Seker نیست.
- محاسبه مستقیم Accuracy بین شماره Cluster و شماره Class ممنوع است؛ مگر اینکه ابتدا یک روش نگاشت مستند میان Cluster ها و کلاس‌ها تعریف شود.

۱۱. مقایسه Class و Cluster

دو Scatter Plot با محورهای یکسان رسم کنید:

- نمودار اول با رنگ Class واقعی
 - نمودار دوم با رنگ Cluster تولیدشده توسط K-Means
- برای این نمودار از دو ویژگی مناسب مانند موارد زیر استفاده کنید:

• Area و Eccentricity

• Compactness و Roundness

سپس توضیح دهید:

- آیا بعضی Cluster ها تقریباً با یک Class منطبق‌اند؟
- آیا یک Class میان چند Cluster تقسیم شده است؟
- آیا یک Cluster شامل چند Class متفاوت است؟

- چرا وجود هفت کلاس به معنی کشف دقیق هفت کلاس توسط K-Means نیست؟

۱۲. مقایسه نهایی

جدول: KNN

مدل	Scale	K	Train Accuracy	Test Accuracy	Macro Recall	Macro F1
KNN	بله	۳				
KNN	بله	۵				
KNN	بله	۹				

جدول: K-Means

Cluster	تعداد اعضا	کلاس غالب	درصد کلاس غالب	سایر کلاس‌های مهم
۰				
۱				
...				
۶				

KNN و K-Means نباید فقط با یک عدد Accuracy با یکدیگر مقایسه شوند؛ زیرا یکی از Label های واقعی استفاده می‌کند و دیگری بدون Label ساختار داده را کشف می‌کند.

۱۳. چالش ابعاد و فاصله

در گزارش توضیح دهید:

- چرا زیاد شدن تعداد ویژگی‌ها می‌تواند مفهوم فاصله را در KNN ضعیف کند؟
 - آیا تمام ۱۶ ویژگی اطلاعات مستقل دارند؟
 - وجود همبستگی زیاد میان Area، Perimeter و EquivDiameter چه اثری دارد؟
 - چرا Scale مشکل اختلاف واحدها را کاهش می‌دهد اما مشکل ویژگی‌های تکراری را کاملاً حل نمی‌کند؟
- نیازی به استفاده از PCA یا Feature Selection نیست؛ فقط مسئله را تحلیل کنید.

پرسش‌های نهایی

- آیا کلاس‌های دیتاست متوازن هستند؟
- کدام نوع لوبیا کمترین Recall را داشت؟
- کدام دو کلاس بیشتر با یکدیگر اشتباه شدند؟

۴. تغییر K چه اثری بر عملکرد KNN داشت؟
۵. چرا Scale برای KNN و K-Means مهم است؟
۶. آیا Clusterهای K-Means با کلاس‌های واقعی منطبق شدند؟
۷. چرا شماره Cluster را نمی‌توان مستقیماً مانند Class تفسیر کرد؟
۸. تفاوت اصلی Supervised Classification و Unsupervised Clustering چیست؟
۹. چه محدودیت‌هایی برای استفاده از مدل در خط بسته‌بندی واقعی وجود دارد؟

خروجی‌ها

- Jupyter Notebook قابل اجرای کامل
- گزارش PDF بین ۵ تا ۷ صفحه
- فایل README.md
- Confusion Matrix هفت‌کلاسه
- جدول ارتباط Class و Cluster
- دو نمودار مقایسه Class واقعی و Cluster